Licenciatura em Engenharia Informática

Algoritmos e Estruturas de Dados

Word Ladder

João Catarino
NMec: 93096

Rúben Garrido
NMec: 107927

Nuno Vieira
NMec: 107283

13 de janeiro de 2023

Índice

1 Introdução

Este trabalho centra-se no estudo de dicionários de palavras, interpretando cada um como um grafo não-orientado, onde cada nó representa uma palavra. Palavras que diferem num só caracter são unidas por um arco. Deste modo, é possível determinar *word ladders* entre palavras: os caminhos mais curtos entre elas, compostos por outras palavras. Por exemplo, *tudo, todo, nodo, nado, nada* é uma *word ladder* entre as palavras *tudo* e *nada*. Os objetivos deste trabalho incluem implementar uma *hash table*, a representação de um grafo não-orientado e a estrutura de dados *union find*, bem como determinar o componente complexo de uma palavra, o diâmetro de um componente conexo e a maior *word ladder* existente no dicionário fornecido.

2 Representação do problema

A implementação do grafo foi feita através de uma *linked hash table*, uma vez que esta possui uma complexidade computacional $O(1)$ para a inserção e procura de elementos. Esta complexidade computacional é importante, dado que a geração de arcos entre palavras implica verificar se todas a permutações de mudança de um caracter de um nó correspondem a palavras contidas no dicionário. Para além disso, caso a complexidade computacional fosse $O(n)$ e existisse um número avultado de palavras, a *word ladder* poderia demorar algum tempo a ser gerada.

A *linked hash table* é composta por um array de *buckets*: *linked lists* que contêm nós. Nós aos quais sejam atribuidos o mesmo índice de array pela função de dispersão são colocados no inicio da lista presente nesse índice. Cada nó contém uma *linked list* onde são guardadas referências aos nós adjacentes. A figura **??** mostra a estrutura da *hash table*.

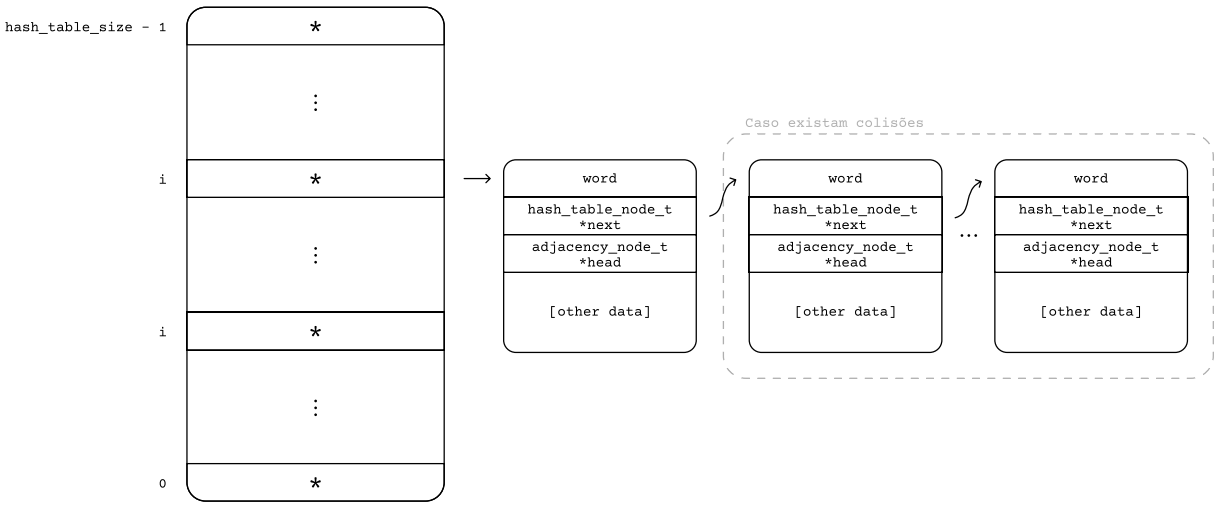

Figura 1: Estrutura da *hash table*

Os índices são calculados através do resto da divisão entre o valor retornado por uma *hash function* e o tamanho da *hash table*. A *hash function* utilizada faz uso do algoritmo `CRC32` (acrónimo de *Cyclic Redudancy Check*, 32 bits).

3 Implementação

3.1 Funções de *hash table*

hash_table_create

Esta função aloca memória para uma estrutura de dados do tipo definido `hash_table_t`, que representa a *hash table*, e para o seu *array* interno `heads` que irá conter as entradas da tabela.

O tamanho inicial da tabela é definido no macro `_hash_table_init_size_` e as suas entradas são inicializadas a zero de forma implícita pela função `calloc`. No final, é guardado o tamanho inicial da tabela na estrutura de dados. A função termina o programa se uma das alocações não for bem sucedida.

hash_table_grow

`hash_table_grow` é a função responsável por aumentar o tamanho da *hash table*. A sua condição de incremento depende do rácio entre o tamanho desta e o número de colisões, onde, caso seja superior a 5, verificar-se-á o incremento. A função inicializa uma nova tabela (com um tamanho igual ao dobro da anterior) usando a função `calloc` e, para cada *node* desta, recalcula o seu índice, através da função `crc32`, e insere-o na nova tabela. Por fim, os endereços para o array `heads` e para o tamanho da tabela (`hash_table_size`) são atualizados.

hash_table_free

Esta função desaloca a memória previamente reservada para a *hash table* e outras estruturas de dados nela contidas. Esta começa por iterar sobre todas as posições do *array*, chamando a função `free_hash_llist`, libertando a *linked list* nessa posição. Por sua vez, esta irá iterar sobre todos os nós da lista através do ponteiro `next` e chamar a função `free_hash_table_node` sobre cada nó, que irá primeiro libertar a lista de adjacência com a função `free_adjacency_llist` e depois o próprio nó. A função `free_adjacency_llist` simplesmente itera sobre todos os membros da lista ligada e liberta cada um deles.

create_word_node

Cria um novo nó de *hash table* com a palavra fornecida como argumento. Este nó, cuja memória alocada é obtida através da função `allocate_hash_table_node`, é inicializado com a palavra e alguns parâmetros predefinidos. Por fim, a função retorna o endereço do *node* recém-criado.

3.2 Funções de grafo

find_word

Função dedicada à procura e inserção de elementos na *hash table*. É calculado o índice, que resulta do resto da divisão entre o resultado da aplicação da *hash function* à palavra desejada (ver secção **??**) e o tamanho máximo da tabela. Esta operação distribui o indice da palavra entre 0 e o tamaho da tabela. De seguida, a função itera sobre a lista ligada na posição calculada, procurando um nó igual através da função `strcmp`, e retorna-o se for o caso. Caso a palavra não exista e a opção `insert_if_not_found` seja verdadeira, o programa aloca um novo nó para a palavra através da função `create_word_node` e coloca-o na lista ligada, atualizando os valores estatísticos na *hash table*.

similar_words

É responsável por encontrar palavras semelhantes à palavra fornecida como argumento. A verificação é baseada em caracteres *Unicode*, onde, para cada caracter da palavra, este é substituído pelos vários caracteres aceites. Caso a nova palavra exista na *hash table*, é efetuada uma chamada à função `add_edge` (ver secção **??**). A função termina quando não existirem mais caracteres para substituir.

find_representative

Função responsável pela determinação do nó representante do componente conexo de um nó requisitado. Antes de devolver o resultado, a função atualiza os representates dos nós percorridos anteriormente.

O seu funcionamento consiste em iterar sobre o representante do nó dado como argumento recursivamente até que o representante de um nó seja ele próprio. Após determinar o representante, esta parte novamente do nó passado como argumento e altera o representante de forma recursiva para o anteriormente determinado até chegar a este novamente. Desta forma, o caminho para o representante é simplificado e as chamadas posteriores com o mesmo nó como argumento serão mais rápidas.

add_edge

Esta função tenta adicionar um arco entre um nó existente e uma palavra que pode não existir, para além de implementar os aspetos da estrutura de dados *Union-Find*. Esta começa por procurar a *string* dada no grafo, retornando caso não a encontre. Caso contrário, procura o segundo nó na lista de adjacência do primeiro e retorna se for o caso, para garantir que o arco não é duplicado. Ao adicionar o arco, é incrementado o contador de arcos da tabela e são adicionados nós de adjacência às tabelas de adjacência das palavras.

A função `insert_edge` trata de alocar o nó de adjacência para cada vértice e de os colocar nas listas respetivas. Neste sentido, a função trata de executar a operação *Union* entre os conjuntos (componentes conexos) de cada vértice. Primeiro, são determinados os representantes de cada um através da função `find_representative` vista anteriormente. Se estes forem diferentes, a operação ocorre. Para minimizar o tamanho do caminho de representantes, o nó com menos vértices na altura da operação é escolhido como o representante do novo componente conexo. Finalmente, são somados os numeros de vértices e arcos, é decrementado o número de componentes e é atualizado o tamanho do maior componente.

breadh_first_search

A função `breadh_first_search`, cujos argumentos são o número máximo de vértices, uma lista de vértices, o array de origem e o ponto de destino, tem como objetivo retornar o número de vértices visitados. Se for especificado o destino, será possível obter o caminho mais curto até este seguindo recursivamente o seu ponteiro `previous`. Para este efeito, é utilizado o algoritmo *Breadth-first search*. Este percorre uma árvore nivel a nivel, garantindo o menor percurso para cada nó visitado. Foi implementada para este caso uma *queue* circular, de forma a garantir que o tamanho máximo desta é constante.

Em primeiro lugar, é efetuada uma chamada à função `allocate_ptr_queue` – que devolve uma *queue* –, e uma chamada à função `queue_put_hi`, que aceita como parâmetros de entrada a *queue* e o array de origem. De seguida, dentro de um ciclo `while` onde o tamanho da *queue* é positivo, é incrementado os valores de `visited` e `list_len`, e, num ciclo `for`, são atualizados os valores e endereços de `vertex->visited` e `vertex->previous`.

3.3 Funções de *queue*

allocate_ptr_queue

Esta função aloca memória para uma *queue* de ponteiros. Esta operação começa por alocar memória para a estrutura de metadados da *queue*, que contêm as variáveis necessárias para o manipulamento de uma *queue*. Posteriormente, é alocado o *array* circular de ponteiros. Finalmente, são inicializadas as variáveis de controlo da estrutura de dados e o seu ponteiro é devolvido.

free_ptr_queue

A função que liberta a memória alocada para a *queue*. Isto implica apenas libertar o seu *array* circular e finalmente a própria estrutura.

queue_put_hi

Implementação da operação *enqueue*, onde um elemento, neste caso um ponteiro, é adicionado ao final da fila. A função começa por executar um *assert* para assegurar que o tamanho da fila não é ultrapassado. Depois, é inserido o novo elemento na posição *hi*. Este valor não representa na verdade o final da fila, mas sim a posição imediatamente asseguir. O valor é agora incrementado e assume o valor do resto da sua divisão pelo tamanho máximo da *queue*. Isto implica que para valores menores que o maior índice possível, *hi* mantem-se, caso contrário, volta à posição 0, garantindo a circularidade.

queue_get_lo

Implementação da operação *dequeue*, onde o elemento inicial da fila é removido e devolvido. A operação começa por um *assert*, para garantir que o programa não tenta remover um elemento de uma fila vazia. De seguida, o valor na posição *lo* é guardado numa variável temporária. Isto é feito porque o inicio da fila pode "saltar" para o outro lado após a sua incrementação. Tendo o valor guardado, é atualizada a posição *lo* da mesma forma como na função `queue\_put\_hi`. No final, é devolvido o valor guardado.

4 *Word ladders* interessantes

4.1 Palavras com 4 letras

A maior *word ladder* encontrada ocorre entre as palavras "Kong" e "está":

1. Kong
2. King
3. Ping
4. Pina
5. tina
6. tino
7. tipo
8. aipo
9. arpo
10. arpe
11. arte
12. ante
13. ente
14. este
15. está

5 Verificação de *memory leaks*

Para verificar se existem *memory leaks* no programa criado, foi utilizado o *Valgrind*, um programa constituído por um conjunto de ferramentas para a deteção de erros de memória e de *threading*. Para o efeito, foi utilizado o *Memcheck*, que é uma ferramenta para deteção de erros de memória.

Obteve-se o seguinte resultado, para o programa `solution_word_ladder.c`, com o ficheiro `wordlist-four-letters.txt` como argumento:

```
==500745== Memcheck, a memory error detector
==500745== Copyright (C) 2002-2022, and GNU GPL'd, by Julian Seward et al.
==500745== Using Valgrind-3.19.0 and LibVEX; rerun with -h for copyright info
==500745== Command: ./solution_word_ladder wordlist-four-letters.txt
==500745==
Your wish is my command:
  1 WORD       (list the connected component WORD belongs to)
  2 FROM TO    (list the shortest path from FROM to TO)
  3 WORD       (list component info)
  4            (list hash table info)
  5            (list graph info)
  0            (terminate)
> 0
==500745==
==500745== HEAP SUMMARY:
==500745==   in use at exit: 0 bytes in 0 blocks
==500745==   total heap usage: 27,700 allocs, 27,700 frees, 60,322,800 bytes
             allocated
==500745==
==500745== All heap blocks were freed -- no leaks are possible
==500745==
==500745== ERROR SUMMARY: 0 errors from 0 contexts (suppressed: 0 from 0)
```

Assim, concluímos que não existem *memory leaks* no programa.

6 Análise do incremento da *hash table*

Por padrão, o tamanho inicial da *hash table* é 1000. No entanto, quando o número de entradas começa a ser significativo, começam a surgir colisões, o que implica uma perca da complexidade computacional $O(1)$. Para evitar este problema, quando o rácio entre o tamanho da *hash table* e o número de colisões é superior a 5, o tamanho da *hash table* é incrementado, através da função `hash_table_grow`, que recebe como argumento a referida *hash table*.

Contudo, a escolha do fator de incremento deve ser ponderada, já que, se for muito pequeno, o número de colisões diminui pouco, e se for muito grande, existe demasiada memória alocada não utilizada, o que leva a um desperdício de recursos. É esta escolha que pretendemos analisar.

6.1 Explicação do código

Foi desenvolvida uma nova função `hash_table_grow`, num programa à parte, em que, após ser verificada a condição de incremento (rácio entre o tamanho da *hash table* e o número de colisões), é percorrido um ciclo `for`, onde são testados vários valores de `j` (fator de incremento).

```
if (hash_table->number_of_collisions > 0 && (hash_table->
 hash_table_size / hash_table->number_of_collisions) < 5)
{
  printf("\nFinding best j. Current hash_table_size is %u.\n",
 hash_table->hash_table_size);
  printf("  j    | new size | memory | free m | colnum\n");
  for (j = 1.1; j < 3; j += 0.005)
  {
```

Dentro deste ciclo, e após inicializar algumas variáveis (p.e., a nova *hash table* temporária), surgem dois novos ciclos `for`.

No primeiro `for`, é percorrida a *hash table* inicial, onde, para cada `node`, é calculado o novo índice, através do resto da divisão entre o valor retornado da função `crc32` e o tamanho da *hash table*. Após este cálculo, é verificada a existência de colisões no índice calculado anteriormente, e, caso existam, é incrementado o valor de `colnum`. Por fim, é associado o nó atual à nova *hash table*, na localização definida pelo índice.

```
    for (i=0; i < hash_table->hash_table_size; i++)
    {
      for (node = hash_table->heads[i]; node; node = next)
      {
        test_new_key = crc32(node->word) % test_new_size;
        next = node->next;
        if (test_new_table[test_new_key])
        {
          colnum++;
        }
        test_new_table[test_new_key] = node;
      }
    }
```

No segundo `for`, é percorrida a nova *hash table*, onde é verificado o número de entradas livres desta. Caso `test_new_table[k]` seja nulo, significa que a posição `k` da *hash table* está livre, e, portanto, é incrementado o valor de `free_entries`.

```
    for (k=0; k < test_new_size; k++) {
      if (!test_new_table[k]) {
        free_entries++;
      }
    }
```

Por último, é impressa uma linha com os dados obtidos, nomeadamente o fator de incremento `j`, o novo tamanho da *hash table* `test_new_size`, a memória total ocupada `test_new_size * sizeof(hash_table_node_t *)`, a memória ocupada por entradas livres `free_entries * sizeof(hash_table_node_t *)` e o número de colisões `colnum`.

```
    printf("%3.3f | %8u | %6lu | %6lu | %6u\n", j, test_new_size,
test_new_size * sizeof(hash_table_node_t *), free_entries * sizeof(
hash_table_node_t *), colnum);
```

6.2 Gráficos obtidos

Através do MATLAB, foi possível obter um conjunto de gráficos, que relacionam colisões com memória livre e memória total. O script, disponível na secção **??**, obtém os dados através de um ficheiro de texto, que contém a tabela imprimida pelo programa de teste.

Os gráficos em questão incidem sobre o primeiro incremento, onde o tamanho atual da *hash table* é 1000.

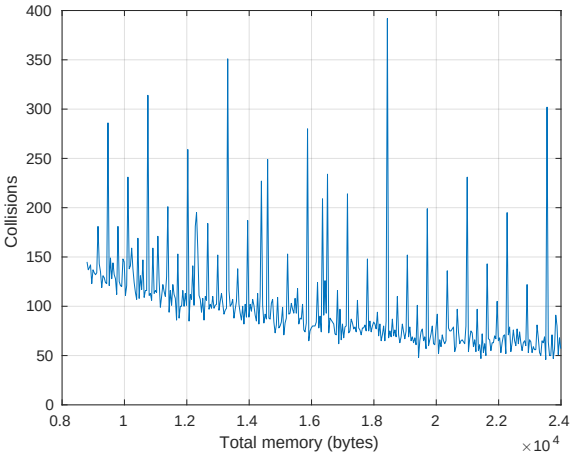

(a) Número de colisões em função da memória total.

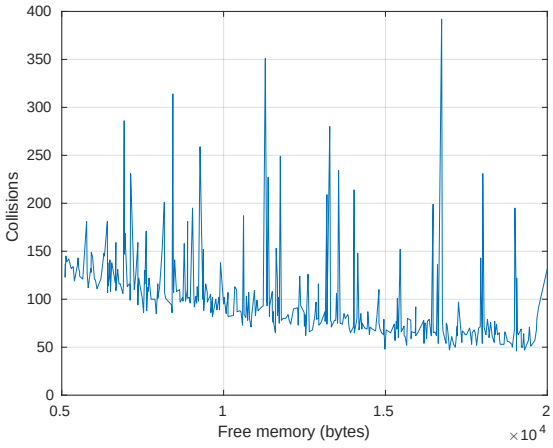

(b) Número de colisões em função da memória livre.

Figura 2: Número de colisões em função da memória.

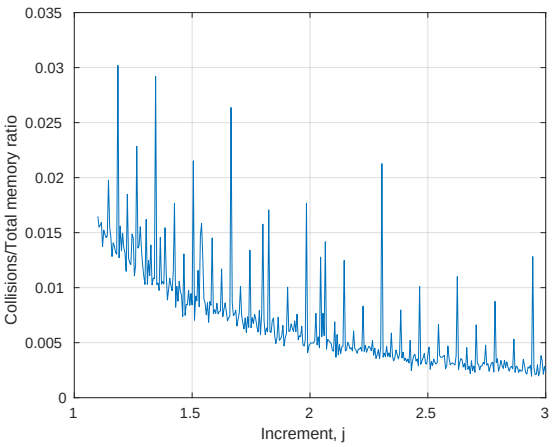

(a) Rácio colisões/memória total.

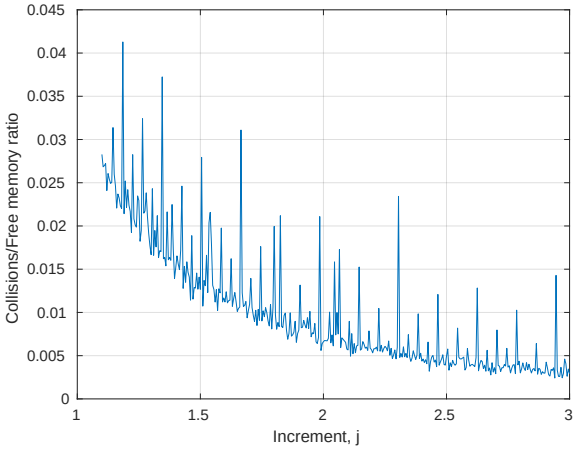

(b) Rácio colisões/memória livre.

Figura 3: Rácio colisões/memória em função do incremento.

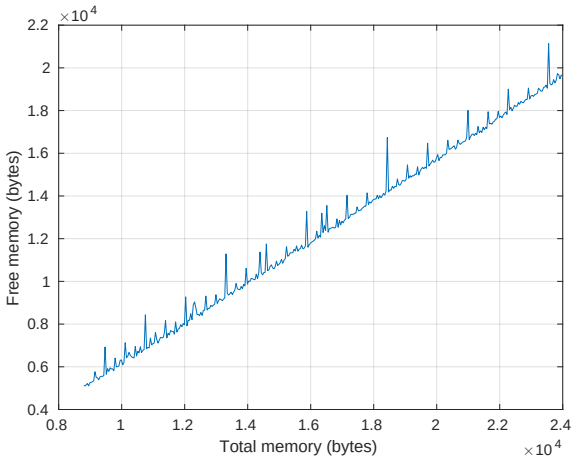

Figura 4: Memória livre em função da memória total.

6.3 Análise dos resultados

Em todos os gráficos, é possível observar irregularidades, associadas a uma maior ou menor quantidade de colisões. Isto deve-se ao facto de a *hash function* não ser perfeita e portanto, consoante o valor de `j`, o índice associado a cada `node` ser diferente.

No entanto, é possível observar que, em geral, o número de colisões diminui com o aumento de memória (ou seja, com incrementos maiores), tal como seria esperado. A relação entre o número de colisões e a memória livre segue a mesma tendência. Em ambos os gráficos, verifica-se uma tendência aproximadamente linear.

Quanto aos rácios colisões/memória em função do incremento, observa-se em ambos os gráficos uma curva descendente, do tipo $a \times x^b$, com $-2 < b < -1$. Por este motivo, verifica-se uma diferença mais acentuada no eixo das ordenadas para incrementos menores do que para incrementos maiores. Assim, considera-se que o melhor incremento é o que apresenta um valor de b mais próximo de 2, já que, a partir desse valor, o rácio tende a ser mais constante. Por outro lado, a similariedade entre rácios explica-se pelo facto de a relação entre a memória livre e a memória total ser aproximadamente linear, com um declive próximo de 1 (ver figura **??**).

No que concerne à relação entre a memória livre e a memória total (ambas em *bytes*), apesar das irregularidades, é possível efetuar uma regressão linear, onde se obtém a equação $y = 0.9583x - 3357$.

Assim, uma vez que os gráficos não são completamente conclusivos quanto ao melhor fator de incremento, escolhemos utilizar o valor 2, já que este constitui um equilíbrio entre o número de colisões e a memória utilizada.

7 Código

7.1 solution_word_ladder.c

```c
#include <stddef.h>
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <assert.h>
#include <sys/param.h>


//
// static configuration
//

#define _max_word_size_  32
#define _hash_table_init_size_ 1000

//
// data structures (SUGGESTION --- you may do it in a different way)
//

typedef struct adjacency_node_s  adjacency_node_t;
typedef struct hash_table_node_s hash_table_node_t;
typedef struct hash_table_s      hash_table_t;
typedef struct ptr_queue_s     ptr_queue_t;

struct ptr_queue_s
{
  void      **circular_array;
  unsigned int  hi;
  unsigned int  lo;
  unsigned int  size;
  unsigned int  max_size;
  int   full;
};

struct adjacency_node_s
{
  adjacency_node_t *next;            // link to th enext adjacency list
   node
  hash_table_node_t *vertex;         // the other vertex
};

struct hash_table_node_s
{
  // the hash table data
  char word[_max_word_size_];        // the word
  hash_table_node_t *next;           // next hash table linked list node
                     // the vertex data
  adjacency_node_t *head;            // head of the linked list of
   adjancency edges
  int visited;                       // visited status (while not in use
   , keep it at 0)
  hash_table_node_t *previous;       // breadth-first search parent
                     // the union find data
```

```
  hash_table_node_t *representative; // the representative of the
   connected component this vertex belongs to
  int number_of_vertices;            // number of vertices of the
   conected component (only correct for the representative of each
   connected component)
  int number_of_edges;               // number of edges of the conected
   component (only correct for the representative of each connected
   component)
  int component_diameter;        // only valid for the representative
   node
};

struct hash_table_s
{
  unsigned int hash_table_size;            // the size of the hash table
    array
  unsigned int largest_component_size;   //size of the biggest component
    (passed on to breadh_first as max list size)
  unsigned int number_of_entries;    // the number of entries in the
   hash table
  unsigned int number_of_collisions; // the total of entries inserted on
    an occupied index
  unsigned int number_of_edges;      // number of edges (for information
    purposes only)
  unsigned int number_of_edge_nodes; // number of edges (for information
    purposes only)
  unsigned int number_of_components; // number of connected components
  hash_table_node_t **heads;         // the heads of the linked lists
};

//
// allocation and deallocation of queue
//

static ptr_queue_t *allocate_ptr_queue(unsigned int max_size)
{
  ptr_queue_t *queue = (ptr_queue_t *)malloc(sizeof(ptr_queue_t));
  if(queue == NULL)
  {
    fprintf(stderr,"allocate_ptr_queue: out of memory\n");
    exit(1);
  }
  queue->circular_array = (void **)malloc(sizeof(void *) * max_size);
  if(queue->circular_array == NULL)
  {
    fprintf(stderr,"allocate_ptr_queue->circular_array: out of memory\n"
   );
    free(queue);
    exit(1);
  }
  queue->max_size = max_size;
  queue->size = 0;
  queue->full = 0;
  queue->hi = 0;
  queue->lo = 0;
  return queue;
}
```

```
static void free_ptr_queue(ptr_queue_t *queue)
{
  free(queue->circular_array);
  free(queue);
}

//
// queue methods
//

static void queue_put_hi(ptr_queue_t *queue, void *ptr)
{
  assert(queue->size < queue->max_size);
  queue->circular_array[queue->hi] = ptr;
  queue->hi = (queue->hi + 1) % queue->max_size;
  queue->size++;
}

static void *queue_get_lo(ptr_queue_t *queue)
{
  assert(queue->size > 0);
  void *ret = queue->circular_array[queue->lo];
  queue->lo = (queue->lo + 1) % queue->max_size;
  queue->size--;
  return ret;
}

//
// allocation and deallocation of linked list nodes (done)
//

static adjacency_node_t *allocate_adjacency_node(void)
{
  adjacency_node_t *node;

  node = (adjacency_node_t *)malloc(sizeof(adjacency_node_t));
  if(node == NULL)
  {
    fprintf(stderr,"allocate_adjacency_node: out of memory\n");
    exit(1);
  }
  return node;
}

static void free_adjacency_llist(adjacency_node_t *head)
{
  adjacency_node_t *next;
  for (; head; head = next)
  {
    next = head->next;
    free(head);
  }
}

static void free_hash_table_node(hash_table_node_t *node)
{
  free_adjacency_llist(node->head);
  free(node);
```

```
}

static hash_table_node_t *allocate_hash_table_node(void)
{
  hash_table_node_t *node;

  node = (hash_table_node_t *)malloc(sizeof(hash_table_node_t));
  if(node == NULL)
  {
    fprintf(stderr,"allocate_hash_table_node: out of memory\n");
    exit(1);
  }
  return node;
}

static void free_hash_llist(hash_table_node_t *head)
{
  hash_table_node_t *next;
  for (; head; head = next)
  {
    next = head->next;
    free_hash_table_node(head);
  }
}


//
// hash table stuff (mostly to be done)
//

unsigned int crc32(const char *str)
{
  static unsigned int table[256];
  unsigned int crc;

  if(table[1] == 0u) // do we need to initialize the table[] array?
  {
    unsigned int i,j;

    for(i = 0u;i < 256u;i++)
      for(table[i] = i,j = 0u;j < 8u;j++)
        if(table[i] & 1u)
          table[i] = (table[i] >> 1) ^ 0xAED00022u; // "magic" constant
        else
          table[i] >>= 1;
  }
  crc = 0xAED02022u; // initial value (chosen arbitrarily)
  while(*str != '\0')
    crc = (crc >> 8) ^ table[crc & 0xFFu] ^ ((unsigned int)*str++ << 24)
   ;
  return crc;
}

static hash_table_t *hash_table_create(void)
{
  hash_table_t *hash_table;

  hash_table = (hash_table_t *)calloc(1, sizeof(hash_table_t));
```

```
  if(hash_table == NULL)
  {
    fprintf(stderr,"create_hash_table: out of memory\n");
    exit(1);
  }
  hash_table->heads = (hash_table_node_t **)calloc(
   _hash_table_init_size_, sizeof(hash_table_node_t *));
  if(hash_table->heads == NULL)
  {
    fprintf(stderr,"create_hash_table: out of memory for array\n");
    exit(1);
  }
  hash_table->hash_table_size = _hash_table_init_size_;
  return hash_table;
}

static void hash_table_info(hash_table_t *hash_table)
{
  printf("Entries: %u\nCollisions: %u\nSize: %u\n",
      hash_table->number_of_entries,
      hash_table->number_of_collisions,
      hash_table->hash_table_size);
}

static void hash_table_grow(hash_table_t *hash_table)
{
  unsigned int    new_size;
  unsigned int    new_key;
  unsigned int    i;
  hash_table_node_t **new_table;
  hash_table_node_t *next;
  hash_table_node_t *node;
  // Determine size_inc based on collision count
  if (hash_table->number_of_collisions > 0 && (hash_table->
   hash_table_size / hash_table->number_of_collisions) < 5)
  {
    new_size = hash_table->hash_table_size * 2;
    new_table = (hash_table_node_t **)calloc(new_size, sizeof(
   hash_table_node_t *));
    if (!new_table)
    {
      fprintf(stderr,"hash_table_grow: out of memory\n");
      exit(1);
    }
    hash_table->number_of_collisions = 0u;
    for (i=0; i < hash_table->hash_table_size; i++)
      for (node = hash_table->heads[i]; node; node = next)
      {
        new_key = crc32(node->word) % new_size;
        next = node->next;
        node->next = new_table[new_key];
        if (node->next)
          hash_table->number_of_collisions++;
        new_table[new_key] = node;
      }
    free(hash_table->heads);
    hash_table->heads = new_table;
    hash_table->hash_table_size = new_size;
```

```
  }
}

static void hash_table_free(hash_table_t *hash_table)
{
  for (unsigned int i = 0; i < hash_table->hash_table_size; i++)
    if (hash_table->heads[i])
      free_hash_llist(hash_table->heads[i]);
  free(hash_table->heads);
  free(hash_table);
}

static hash_table_node_t *create_word_node(const char *word)
{
  hash_table_node_t *node = allocate_hash_table_node();
  node->representative = node;
  node->visited = -1;
  node->number_of_vertices = 1;
  node->number_of_edges = 0;
  node->previous = NULL;
  node->next = NULL;
  node->head = NULL;
  strcpy(node->word, word);
  return node;
}

static hash_table_node_t *find_word(hash_table_t *hash_table,const char
   *word,int insert_if_not_found)
{
  hash_table_node_t *node;
  unsigned int i;

  i = crc32(word) % hash_table->hash_table_size;
  node = hash_table->heads[i];
  while (node)
  {
    if (strcmp(node->word, word) == 0)
      return node;
    node = node->next;
  }
  if (insert_if_not_found)
  {
    node = create_word_node(word);
    if (hash_table->heads[i])
      hash_table->number_of_collisions++;
    node->next = hash_table->heads[i];
    hash_table->heads[i] = node;
    hash_table->number_of_components++;
    hash_table->number_of_entries++;
    hash_table_grow(hash_table);
  }
  return node;
}


//
// add edges to the word ladder graph (mostly do be done)
//
```

```
static hash_table_node_t *find_representative(hash_table_node_t *node)
{
  hash_table_node_t *representative,*next_node;

  for(representative = node; representative != representative->
   representative; representative = representative->representative);

  for(next_node = node; next_node != representative; next_node = node)
  {
    node = next_node->representative;
    next_node->representative = representative;
  }
  return representative;
}

static void insert_edge(hash_table_t *hash_table, hash_table_node_t *
   from, hash_table_node_t *to)
{
  adjacency_node_t *link;

  link = allocate_adjacency_node();
  link->vertex = to;
  link->next = from->head;
  from->head = link;
  hash_table->number_of_edge_nodes++;
}

static void add_edge(hash_table_t *hash_table,hash_table_node_t *from,
   const char *word)
{
  hash_table_node_t *to,*from_representative,*to_representative;
  adjacency_node_t *link;

  to = find_word(hash_table,word,0);
  if (!to)
    return;
  for (link = from->head; link && link->vertex != to; link = link->next)
   ;
  if (link)
    return;
  hash_table->number_of_edges++;
  insert_edge(hash_table, from, to);
  insert_edge(hash_table, to, from);

  from_representative = find_representative(from);
  to_representative = find_representative(to);

  from_representative->number_of_edges++;
  if (from_representative != to_representative)
  {
    unsigned int  vert_sum = from_representative->number_of_vertices +
   to_representative->number_of_vertices;
    unsigned int  edge_sum = from_representative->number_of_edges +
   to_representative->number_of_edges;
    int          cond = to_representative->number_of_vertices >
   from_representative->number_of_vertices;
```

```
    hash_table_node_t *new_rep = cond ? from_representative :
   to_representative;
    new_rep->number_of_vertices = vert_sum;
    new_rep->number_of_edges = edge_sum;
    (cond ? to_representative : from_representative)->representative =
   new_rep;
    hash_table->number_of_components--;
    if (vert_sum > hash_table->largest_component_size)
      hash_table->largest_component_size = vert_sum;
  }
}


//
// generates a list of similar words and calls the function add_edge for
    each one (done)
//
// man utf8 for details on the uft8 encoding
//

static void break_utf8_string(const char *word,int *
   individual_characters)
{
  int byte0,byte1;

  while(*word != '\0')
  {
    byte0 = (int)(*(word++)) & 0xFF;
    if(byte0 < 0x80)
      *(individual_characters++) = byte0; // plain ASCII character
    else
    {
      byte1 = (int)(*(word++)) & 0xFF;
      if((byte0 & 0b11100000) != 0b11000000 || (byte1 & 0b11000000) != 0
   b10000000)
      {
        fprintf(stderr,"break_utf8_string: unexpected UFT-8 character\n"
   );
        exit(1);
      }
      *(individual_characters++) = ((byte0 & 0b00011111) << 6) | (byte1
   & 0b00111111); // utf8 -> unicode
    }
  }
  *individual_characters = 0; // mark the end!
}

static void make_utf8_string(const int *individual_characters,char word[
   _max_word_size_])
{
  int code;

  while(*individual_characters != 0)
  {
    code = *(individual_characters++);
    if(code < 0x80)
      *(word++) = (char)code;
    else if(code < (1 << 11))
```

```
    { // unicode -> utf8
      *(word++) = 0b11000000 | (code >> 6);
      *(word++) = 0b10000000 | (code & 0b00111111);
    }
    else
    {
      fprintf(stderr,"make_utf8_string: unexpected UFT-8 character\n");
      exit(1);
    }
  }
  *word = '\0';  // mark the end
}

static void similar_words(hash_table_t *hash_table,hash_table_node_t *
   from)
{
  static const int valid_characters[] =
  { // unicode!
    0x2D,
          // -
    0x41,0x42,0x43,0x44,0x45,0x46,0x47,0x48,0x49,0x4A,0x4B,0x4C,0x4D,
          // A B C D E F G H I J K L M
    0x4E,0x4F,0x50,0x51,0x52,0x53,0x54,0x55,0x56,0x57,0x58,0x59,0x5A,
          // N O P Q R S T U V W X Y Z
    0x61,0x62,0x63,0x64,0x65,0x66,0x67,0x68,0x69,0x6A,0x6B,0x6C,0x6D,
          // a b c d e f g h i j k l m
    0x6E,0x6F,0x70,0x71,0x72,0x73,0x74,0x75,0x76,0x77,0x78,0x79,0x7A,
          // n o p q r s t u v w x y z
    0xC1,0xC2,0xC9,0xCD,0xD3,0xDA,
          // Á Â É Í Ó Ú
    0xE0,0xE1,0xE2,0xE3,0xE7,0xE8,0xE9,0xEA,0xED,0xEE,0xF3,0xF4,0xF5,0
   xFA,0xFC, // à á â ã ç è é ê í î ó ô õ ú ü
    0
  };
  int i,j,k,individual_characters[_max_word_size_];
  char new_word[2 * _max_word_size_];

  break_utf8_string(from->word,individual_characters);
  for(i = 0;individual_characters[i] != 0;i++)
  {
    k = individual_characters[i];
    for(j = 0;valid_characters[j] != 0;j++)
    {
      individual_characters[i] = valid_characters[j];
      make_utf8_string(individual_characters,new_word);
      // avoid duplicate cases
      if(strcmp(new_word,from->word) > 0)
        add_edge(hash_table,from,new_word);
    }
    individual_characters[i] = k;
  }
}


//
// breadth-first search (to be done)
//
```

```
// returns the number of vertices visited; if the last one is goal,
   following the previous links gives the shortest path between goal and
    origin
//

static int breadh_first_search(unsigned int maximum_number_of_vertices,
   hash_table_node_t **list_of_vertices,hash_table_node_t *origin,
   hash_table_node_t *goal)
{
  unsigned int    list_len;
  hash_table_node_t *node;
  adjacency_node_t  *link;
  ptr_queue_t     *queue;

  queue = allocate_ptr_queue(maximum_number_of_vertices);

  list_len = 0;
  queue_put_hi(queue, origin);
  while (queue->size > 0)
  {
    node = queue_get_lo(queue);
    node->visited++;
    if (list_of_vertices)
      list_of_vertices[list_len] = node;
    list_len++;
    if (node == goal)
      break;
    for(link = node->head; link && list_len < maximum_number_of_vertices
   ; link = link->next)
    {
      if (link->vertex->visited == -1)
      {
        link->vertex->visited = node->visited;
        link->vertex->previous = node;
        queue_put_hi(queue, link->vertex);
      }
    }
  }
  free_ptr_queue(queue);
  if (goal && goal != node)
    return -1;
  return list_len;
}


//
// list all vertices belonging to a connected component (complete this)
//

static void mark_all_vertices(hash_table_t *hash_table)
{
  hash_table_node_t *node;

  for(unsigned int i = 0;i < hash_table->hash_table_size;i++)
    for(node = hash_table->heads[i];node != NULL;node = node->next)
      node->visited = -1;
}
```

```
static void list_connected_component(hash_table_t *hash_table,const char
    *word)
{
  hash_table_node_t *origin, *rep;
  hash_table_node_t **list;
  unsigned int    list_len;

  origin = find_word(hash_table, word, 0);
  if (!origin)
  {
    printf("\nWord not found: %s\n", word);
    return;
  }

  mark_all_vertices(hash_table);
  rep = find_representative(origin);
  list = malloc(rep->number_of_vertices * sizeof(hash_table_node_t *));
  list_len = breadh_first_search(rep->number_of_vertices, list, origin,
   NULL);
  for (unsigned int i=0; i < list_len; i++)
    printf("%s\n", list[i]->word);
  free(list);
}


//
// compute the diameter of a connected component (optional)
//

static int largest_diameter;
static hash_table_node_t **largest_diameter_example;

static int connected_component_diameter(hash_table_node_t *node)
{
  int          diameter;
  unsigned int    j, i, comp_len, search_len;
  hash_table_node_t **comp_nodes, **node_list, *chain_start, *chain_end;

  diameter = 0;
  chain_start = chain_end = NULL;
  comp_nodes = calloc(node->representative->number_of_vertices, sizeof(
   hash_table_node_t *));
  comp_len = breadh_first_search(node->representative->
   number_of_vertices, comp_nodes, node, NULL);
  for (i = 0; i < comp_len; i++)
  {
    for (j = 0; j < comp_len; j++)
      comp_nodes[j]->visited = -1;
    node_list = calloc(node->representative->number_of_vertices, sizeof(
   hash_table_node_t *));
    search_len = breadh_first_search(node->representative->
   number_of_vertices, node_list, comp_nodes[i], NULL);
    if (node_list[search_len - 1]->visited >= diameter)
    {
      diameter = node_list[search_len - 1]->visited;
      chain_start = comp_nodes[i];
      chain_end = node_list[search_len - 1];
    }
```

```
    free(node_list);
  }
  if (diameter > largest_diameter)
  {
    largest_diameter = diameter;
    if (largest_diameter_example)
      free(largest_diameter_example);
    largest_diameter_example = calloc(diameter, sizeof(hash_table_node_t
    *));
    i = diameter;
    for (node = chain_end; node != chain_start; node = node->previous)
      largest_diameter_example[--i] = node;
  }
  free(comp_nodes);
  return diameter;
}


//
// find the shortest path from a given word to another given word (to be
    done)
//

static void path_finder(hash_table_t *hash_table,const char *from_word,
   const char *to_word)
{
  hash_table_node_t *from, *to;
  int          i, list_len;

  // switch from with to in order to print path in correct order
  from = find_word(hash_table, from_word, 0);
  to = find_word(hash_table, to_word, 0);

  if (!from)
  {
    fprintf(stderr, "\nWord not found: %s\n", from_word);
    return ;
  }
  if (!to)
  {
    fprintf(stderr, "\nWord not found: %s\n", to_word);
    return ;
  }

  mark_all_vertices(hash_table);
  list_len = breadh_first_search(find_representative(to)->
   number_of_vertices, NULL, to, from);
  if (list_len == -1)
    fprintf(stderr, "Words are not connected\n");
  else
  {
    i = 0;
    for(; from && from != to; from = from->previous)
      printf(" [%d] %s\n", i++, from->word);
    printf(" [%d] %s\n", i++, from->word);
  }
}
```

```
static void component_info(hash_table_t *hash_table, char *word)
{
  hash_table_node_t *origin, *rep;

  origin = find_word(hash_table, word, 0);
  if (!origin)
    return (void)fprintf(stderr, "\nWord not found.\n");
  rep = find_representative(origin);
  printf("\nRepresentative: %s\nVertices: %u\nEdges: %u\nDiameter: %u\n"
   ,
      rep->word,
      rep->number_of_vertices,
      rep->number_of_edges,
      rep->component_diameter);
}

//
// some graph information (optional)
//

static void graph_info(hash_table_t *hash_table)
{
  printf("\nNodes: %u\nEdges: %u\nEdge nodes: %u\nComponents: %u\
   nLargest Component: %u\n",
      hash_table->number_of_entries,
      hash_table->number_of_edges,
      hash_table->number_of_edge_nodes,
      hash_table->number_of_components,
      hash_table->largest_component_size);
}


//
// main program
//

int main(int argc,char **argv)
{
  char word[100],from[100],to[100];
  hash_table_t *hash_table;
  hash_table_node_t *node, *rep;
  unsigned int i;
  int command;
  FILE *fp;

  largest_diameter_example = NULL;
  largest_diameter = 0;
  // initialize hash table
  hash_table = hash_table_create();
  // read words
  fp = fopen((argc < 2) ? "wordlist-big-latest.txt" : argv[1],"rb");
  if(fp == NULL)
  {
    fprintf(stderr,"main: unable to open the words file\n");
    exit(1);
  }
  while(fscanf(fp,"%99s",word) == 1)
```

```
    (void)find_word(hash_table,word,1);
  fclose(fp);
  // find all similar words
  for(i = 0u;i < hash_table->hash_table_size;i++)
    for(node = hash_table->heads[i];node != NULL;node = node->next)
      similar_words(hash_table,node);
  for(i =0u;i < hash_table->hash_table_size;i++)
    for(node = hash_table->heads[i];node != NULL;node = node->next)
    {
      if (node->visited == -1)
      {
        rep = find_representative(node);
        rep->component_diameter = connected_component_diameter(node);
      }
    }
  printf("Largest diameter: %d, from component: %s\n", largest_diameter,
    find_representative(largest_diameter_example[0])->word);
  printf("Largest word chain:\n");
  for(i=0; i < (unsigned int)largest_diameter; i++)
    printf(" [%d] %s\n", i, largest_diameter_example[i]->word);
  // ask what to do
  for(;;)
  {
    fprintf(stderr,"\nYour wish is my command:\n");
    fprintf(stderr,"  1 WORD       (list the connected component WORD
   belongs to)\n");
    fprintf(stderr,"  2 FROM TO    (list the shortest path from FROM to
   TO)\n");
    fprintf(stderr,"  3 WORD       (list component info)\n");
    fprintf(stderr,"  4            (list hash table info)\n");
    fprintf(stderr,"  5            (list graph info)\n");
    fprintf(stderr,"  0            (terminate)\n");
    fprintf(stderr,"> ");
    if(scanf("%99s",word) != 1)
      break;
    command = atoi(word);
    if(command == 1)
    {
      if(scanf("%99s",word) != 1)
        break;
      list_connected_component(hash_table,word);
    }
    else if(command == 2)
    {
      if(scanf("%99s",from) != 1)
        break;
      if(scanf("%99s",to) != 1)
        break;
      path_finder(hash_table,from,to);
    }
    else if(command == 3)
    {
      if(scanf("%99s",word) != 1)
        break;
      component_info(hash_table, word);
    }
    else if(command == 4)
      hash_table_info(hash_table);
```

```
    else if(command == 5)
      graph_info(hash_table);
    else if(command == 0)
      break;
  }
  // clean up
  hash_table_free(hash_table);
  if (largest_diameter_example)
    free(largest_diameter_example);
  return 0;
}
```

7.2 Função hash_table_grow que testa o melhor incremento

```
static void hash_table_grow(hash_table_t *hash_table)
{
  unsigned int    i;
  double         j;
  unsigned int    k;
  unsigned int    test_new_size;
  unsigned int    test_new_key;
  hash_table_node_t *next;
  hash_table_node_t *node;
  hash_table_node_t **test_new_table;
  unsigned int    colnum;
  unsigned int    free_entries;

  if (hash_table->number_of_collisions > 0 && (hash_table->
   hash_table_size / hash_table->number_of_collisions) < 5)
  {
    printf("\nFinding best j. Current hash_table_size is %u.\n",
   hash_table->hash_table_size);
    printf("  j    | new size | memory | free m | colnum\n");
    for (j = 1.1; j < 3; j += 0.005)
    {
      colnum = 0u;
      free_entries = 0u;
      test_new_size = (double)hash_table->hash_table_size * j;
      test_new_table = (hash_table_node_t **)calloc(test_new_size,
   sizeof(hash_table_node_t *));

      for (i=0; i < hash_table->hash_table_size; i++)
      {
        for (node = hash_table->heads[i]; node; node = next)
        {
          test_new_key = crc32(node->word) % test_new_size;
          next = node->next;
          if (test_new_table[test_new_key])
          {
            colnum++;
          }
          test_new_table[test_new_key] = node;
        }
      }
      for (k=0; k < test_new_size; k++) {
        if (!test_new_table[k]) {
          free_entries++;
        }
      }
      printf("%3.3f | %8u | %6lu | %6lu | %6u\n", j, test_new_size,
   test_new_size * sizeof(hash_table_node_t *), free_entries * sizeof(
   hash_table_node_t *), colnum);
    }
  }
}
```

7.3 Script MATLAB que gera os gráficos para análise da hash_table_grow

```
% Get data from file
table = load("first.txt");
j = table(:,1);
new_size = table(:,2);
memory = table(:,3);
free_memory = table(:,4);
collisions = table(:,5);

% Sort free_memory & collisions arrays, based on free_memory
[free_memory_sorted,sortIdx] = sort(free_memory,'ascend');
collisions_sorted = collisions(sortIdx);

% Get ratios
ratio_col_mem = collisions./memory;
ratio_col_free = collisions./free_memory;

% Plots
figure(1)
plot(memory,collisions)
xlabel('Total memory (bytes)')
ylabel('Collisions')
grid on

figure(2)
plot(free_memory_sorted,collisions_sorted)
xlabel('Free memory (bytes)')
ylabel('Collisions')
grid on
xlim([5000 20000])

figure(3)
plot(j,ratio_col_mem)
xlabel('Increment, j')
ylabel('Collisions/Total memory ratio')
grid on

figure(4)
plot(j,ratio_col_free)
xlabel('Increment, j')
ylabel('Collisions/Free memory ratio')
grid on

figure(5)
plot(memory,free_memory)
xlabel('Total memory (bytes)')
ylabel('Free memory (bytes)')
grid on
```